

M2.851. Memoria Práctica 1

Nombres de los integrantes del grupo.: David Conesa Muiña

El enlace al sitio web elegido: <https://www.imdb.com/chart/top/>

*El enlace al repositorio con el código de la práctica:
<https://github.com/davidconesa73/Practica-1-M2.851>*

El enlace al dataset publicado en Zenodo: <https://doi.org/10.5281/zenodo.19476345>

1. Contexto.

El objetivo de la práctica era construir un dataset a partir de un sitio web real, cumpliendo los requisitos de descubrimiento automático de enlaces, navegación autónoma, uso responsable del scraping y sin utilizar APIs como fuente principal. Antes de llegar a la solución final, se realizaron numerosos intentos con distintos portales reales que permitieron entender en profundidad cómo funcionan hoy en día las páginas web modernas y por qué el scraping tradicional basado únicamente en HTML suele fallar.

Los primeros intentos se centraron en portales inmobiliarios como **Idealista** (Idealista), **Fotocasa** (Fotocasa) y **pisos.com** (pisos.com), ya que ofrecían datos muy estructurados (precio, ubicación, características del inmueble) y parecían ideales para un análisis posterior. Sin embargo, en los tres casos aparecieron fuertes sistemas anti-scraping: bloqueos por comportamiento sospechoso, mensajes del tipo “*Pardon our interruption*”, detección de Selenium/Chromedriver, banners de cookies que impedían la carga del contenido y, sobre todo, un problema común: **el HTML que se descargaba no contenía realmente los datos visibles en el navegador**, ya que estos se generaban dinámicamente mediante JavaScript.

Posteriormente se probó con la sección de empresas de **Y Combinator** (Y Combinator), que parecía muy adecuada por la riqueza de información de cada startup. Aquí el obstáculo principal fue el *infinite scroll* y la carga completa del contenido mediante datos JSON internos que el frontend renderiza dinámicamente. Incluso utilizando

Selenium, los selectores clásicos no funcionaban porque los elementos no existían inicialmente en el DOM.

También se intentó con el e-commerce **PCComponentes** (PCComponentes) y la tienda online de vinos **Decántalo** (Decántalo). En estos casos se comprobó cómo muchos comercios electrónicos detectan explícitamente el uso de WebDriver y cómo un archivo *robots.txt* complejo puede condicionar completamente la estrategia de scraping responsable. En Decántalo, por ejemplo, el robots estaba extremadamente restringido al tratarse de una web basada en PrestaShop con múltiples reglas anti-bot.

Todos estos intentos no fueron fallidos, sino fundamentales para comprender un patrón clave: **las webs modernas no exponen sus datos como HTML estático, sino como información dinámica generada por JavaScript o embebida en estructuras JSON internas.**

Finalmente los datos se han recolectado a partir del listado **Top 250 películas** del sitio web oficial de **IMDb**, accesible en la dirección:

<https://www.imdb.com/chart/top/>

A partir de este listado inicial, el script desarrollado realiza **descubrimiento automático de enlaces** hacia la página individual de cada película y navega de forma autónoma por ellas para extraer la información. Este proceso cumple con el requisito de la práctica de no limitarse a una única página estática, sino recorrer el sitio web siguiendo su propia estructura de enlaces.

La recolección se ha realizado mediante Selenium simulando un navegador real y extrayendo los datos desde el bloque **JSON-LD** que IMDb incorpora en cada página de película. Este formato está pensado precisamente para describir la información de forma estructurada y semántica, lo que garantiza que los datos obtenidos son los mismos que utiliza la propia web para representar la información.

El contexto específico de los datos es, por tanto:

Películas consideradas por los usuarios de IMDb como las 250 mejor valoradas de la historia del cine, junto con sus características principales (título, año, duración, géneros, director, reparto principal, puntuación y número de votos).

Este contexto es especialmente adecuado para un análisis posterior porque combina:

- **Datos numéricos:** puntuación, número de votos, año, duración.
- **Datos categóricos:** géneros, directores, actores.
- **Datos textuales:** título.

Pertinencia y fiabilidad del sitio web

IMDb es una de las bases de datos cinematográficas más importantes y utilizadas a nivel mundial. La información que contiene proviene de:

- Contribuciones verificadas de usuarios y profesionales del sector.
- Procesos de moderación y validación propios de la plataforma.
- Uso masivo por parte de la industria audiovisual y del público general como referencia estándar.

El ranking *Top 250* no es arbitrario, sino que se calcula a partir de un algoritmo propio basado en millones de valoraciones de usuarios, lo que lo convierte en un indicador colectivo y representativo de la percepción pública sobre las películas.

Además, IMDb presenta varias características que la convierten en una fuente especialmente fiable para esta práctica:

- Estructura web estable y coherente.
- Datos presentados de forma estructurada mediante JSON-LD.
- Accesibilidad pública sin necesidad de autenticación.
- Contenido consistente entre páginas, lo que permite una extracción sistemática y reproducible.

Por todo ello, IMDb no solo cumple con los requisitos técnicos de la práctica, sino que constituye una fuente pertinente, fiable y rica en información para la construcción de un dataset con potencial analítico real.

2. Título.

Extracción automatizada y estructuración de datos cinematográficos desde IMDb: construcción de un dataset a partir del Top 250 de películas mediante Selenium y JSON-LD

3. Descripción del dataset.

El dataset generado contiene información estructurada de **250 películas** pertenecientes al listado *Top 250* de **IMDb**, obtenida a partir de la navegación automática desde la página principal del ranking hacia la página individual de cada película.

Cada fila del dataset corresponde a una película y cada columna a un atributo extraído de su página específica. Los datos han sido obtenidos a partir del bloque **JSON-LD** embebido en el código fuente de IMDb, lo que garantiza una estructura coherente y homogénea entre registros.

Características del dataset

- **Número de registros:** 250 películas.
- **Origen de los datos:** páginas individuales de cada película dentro de IMDb.
- **Estructura homogénea:** todos los registros comparten el mismo esquema gracias al uso del JSON-LD.
- **Datos reales y actuales:** procedentes directamente del sitio web oficial en el momento del scraping.
- **Variedad tipológica de datos:** permite aplicar técnicas estadísticas, de limpieza, transformación y análisis en la siguiente práctica.


Potencial analítico

El contenido del dataset permite estudiar patrones interesantes dentro del cine mejor valorado por la comunidad de usuarios de IMDb, tales como:

- Relación entre puntuación y número de votos.
- Distribución de géneros entre las películas mejor valoradas.
- Análisis de directores y actores más presentes en el ranking.
- Tendencias temporales según el año de estreno.
- Análisis de la duración media por género.

4. Representación gráfica


Los siguientes gráficos de ejemplo han sido creados usando Rstudio, específicamente ggplot2. Muestran diferentes relaciones entre los datos.



Distribución de las valoraciones del top 250 de películas. La línea negra es la media de las puntuaciones. El mayor número se encuentra alrededor del 8,1 o 8,2.

Distribución de duración de las películas


Predominan películas largas, propias del cine épico y dramático



La distribución de la duración de las películas tiene su mayor número sobre los 120 minutos.


Top 10 géneros más frecuentes

Predominio claro del drama y el crimen



El género que más destaca es el drama.

Duración según nivel de rating



Se observa una relación entre duración y mejores ratings aunque se debería profundizar más al respecto.

5. Contenido.

El dataset generado recoge información de 250 películas pertenecientes al ranking **Top 250**.

Cada registro del conjunto de datos corresponde a una película y contiene información descriptiva extraída de su ficha pública individual dentro del sitio web.

Periodo temporal de los datos

Las películas incluidas abarcan un amplio rango temporal que va desde **1931 hasta la actualidad**, ya que el ranking incluye obras clásicas y contemporáneas. Por tanto, el dataset no representa un periodo concreto de recolección histórica, sino una **fotografía actual** del ranking en el momento en que se realizó el scraping.

La recolección de los datos se realizó en **abril de 2026**, por lo que los valores de puntuación (rating) y número de votos (votes) corresponden al estado de la plataforma en ese momento y pueden variar con el tiempo.

Campos incluidos en el dataset

Los campos que componen el dataset son los siguientes:

Campo	Descripción	Tipo de dato
title	Título oficial de la película mostrado en IMDb	Categorico (texto)
year	Año de estreno de la película	Numérico discreto
rating	Puntuación media otorgada por los usuarios (0-10)	Numérico continuo

votes	Número total de votos recibidos	Numérico discreto
duration	Duración original mostrada en horas y minutos	Categorico (texto)
duration_min	Duración convertida a minutos para facilitar análisis	Numérico continuo
genres	Géneros cinematográficos asociados	Categorico múltiple
director	Director o directores de la película	Categorico múltiple
stars	Actores principales que aparecen en la ficha	Categorico múltiple

Naturaleza del contenido

El conjunto de datos combina:

- **Variables cuantitativas:** año, puntuación, votos, duración en minutos.
- **Variables cualitativas:** géneros, directores, actores.

Esto da lugar a un dataset equilibrado que permite realizar análisis tanto estadísticos como semánticos en prácticas posteriores.

6. Propietario

El conjunto de datos utilizado en este proyecto procede íntegramente de la plataforma IMDb (Internet Movie Database), cuya dirección web es:

<https://www.imdb.com>

IMDb es una base de datos cinematográfica de referencia a nivel mundial, propiedad de Amazon desde 1998. Se trata de una de las fuentes más reconocidas, consultadas y citadas en estudios relacionados con el cine, la televisión y la industria audiovisual. La

información que contiene es mantenida tanto por personal editorial como por contribuciones de usuarios, bajo procesos de validación internos.

Análisis y trabajos similares con datasets de IMDb

Existen múltiples trabajos, estudios y proyectos que han utilizado conjuntos de datos basados en IMDb para realizar análisis de datos, aprendizaje automático y visualizaciones, lo que demuestra que los datos provenientes de esta plataforma son ampliamente relevantes y útiles para distintos fines investigativos y analíticos.

Ejemplos de trabajos y análisis relevantes

1. Dataset “Top 250 IMDb” publicado en Zenodo

Un proyecto previo recopiló un conjunto de datos con las 250 películas mejor valoradas en IMDb que incluye metadatos como título, puntuación y género, y fue publicado con un DOI en Zenodo para uso académico y de investigación. ([Zenodo](#))

2. Análisis completo de IMDb con Python

En múltiples repositorios de GitHub y portales como Kaggle se han realizado estudios con datasets que contienen miles de películas con características similares a las extraídas en este proyecto (título, género, año, rating, director, etc.), con análisis exploratorio, tendencias por año o visualizaciones de datos. ([GitHub](#))

3. Análisis EDA de datos de IMDb descargables

Varios tutoriales de análisis de datos utilizan los archivos .tsv proporcionados por IMDb (que pueden descargarse directamente desde sus interfaces oficiales) para hacer exploraciones estadísticas de variables como rating, género, duración y más. ([Medium](#))

4. Estudios académicos con datos de IMDb

Publicaciones científicas han utilizado datasets relacionados con IMDb para tareas avanzadas como análisis de sentimiento de reseñas, modelado de temas o extracción de factores que influyen en el éxito de una película. Por ejemplo, investigadores han empleado técnicas de aprendizaje profundo para analizar sentimientos o tendencias en reseñas de películas basadas en grandes conjuntos de datos extraídos de IMDb. ([researchgate.net](#))

5. Proyectos universitarios de análisis de ratings y taquilla

En contextos formativos de ciencia de datos y estadística también se ha utilizado IMDb junto a datos de recaudación y ratings para entender mejor la relación entre características cinematográficas y éxito financiero o valoración de audiencia. ([El Éxito en el Cine](#))

Comparación con nuestro enfoque

Muchos de estos trabajos comparten objetivos similares con el presente proyecto, como:

- Realizar exploración visual de los datos.
- Entender las relaciones entre variables como rating, género y año.
- Estudiar tendencias a lo largo del tiempo.
- Crear visualizaciones que faciliten la interpretación de resultados.

Sin embargo, en contraste con algunos conjuntos de datos ya preformateados (por ejemplo, datasets descargados de Kaggle o derivados de las tablas .tsv oficiales), este proyecto ha aplicado **web scraping con Selenium** para generar un dataset desde cero únicamente con información pública disponible en las páginas web. Esto hace que el enfoque metodológico no solo utilice los datos, sino que también aborde **el proceso de recolección automática**, lo cual no siempre es tratado en los análisis previos.

En suma, los trabajos existentes muestran que los datasets basados en IMDb son valiosos para diversas aplicaciones (análisis exploratorio, machine learning, sentimientos, modelado estadístico), y nuestro proyecto se sitúa dentro de ese contexto como un ejemplo de generación y uso de datos de IMDb desde la extracción automática hasta el análisis visual y descriptivo.

Consideraciones éticas y legales

Para la obtención del dataset se han seguido una serie de principios éticos y legales:

- **Acceso únicamente a información pública:**
Solo se han recolectado datos visibles sin necesidad de autenticación ni acceso a zonas privadas del sitio.
- **Respeto al fichero robots.txt:**
Se ha consultado el archivo robots.txt del dominio, observando qué secciones

están restringidas para bots y cuáles son accesibles. La sección /chart/top/ y las fichas públicas de películas no están bloqueadas explícitamente.

- **Uso responsable de las peticiones:**

El scraping se ha realizado con pausas entre peticiones para no sobrecargar el servidor y simular un comportamiento humano razonable.

- **Finalidad académica y no comercial:**

La recolección se ha llevado a cabo exclusivamente con fines docentes, dentro del marco de la asignatura y sin ningún uso comercial de la información.

- **No almacenamiento de contenido protegido:**

No se han descargado imágenes, vídeos ni textos extensos protegidos por derechos de autor, únicamente metadatos descriptivos (título, año, géneros, etc.).

Justificación del procedimiento

El proceso seguido se ajusta a los principios del ciclo de vida de los datos y a las buenas prácticas de web scraping ético:

- Identificación del propietario de la información.
- Revisión de las políticas de acceso automatizado.
- Extracción limitada a metadatos relevantes.
- Uso con fines educativos y analíticos.

Por todo ello, se considera que la obtención del dataset respeta tanto el marco legal como el ético del uso de datos disponibles públicamente en IMDb.

7. Inspiración.

El dataset obtenido a partir del Top 250 de IMDb resulta especialmente interesante porque combina información técnica objetiva de las películas (año, duración, géneros, dirección, reparto) con información agregada de percepción colectiva (valoración media y número de votos de millones de usuarios).

Esto permite trabajar con un conjunto de datos que mezcla variables numéricas y categóricas y, además, introduce una dimensión social: la opinión global de la audiencia a lo largo del tiempo.

A diferencia de los intentos anteriores realizados con portales inmobiliarios como Fotocasa e Idealista, donde los datos eran muy volátiles, dependientes de filtros de búsqueda y con estructuras pensadas para impedir la automatización, el sitio seleccionado presenta una estructura estable, coherente y altamente estructurada, pensada precisamente para catalogar información. Tal como se ha explicado en el apartado 6, IMDb es una base de datos cinematográfica consolidada, ampliamente utilizada tanto por usuarios como por investigadores y medios especializados, lo que refuerza el valor analítico del dataset.

Este conjunto de datos permite plantear preguntas de análisis muy diversas, por ejemplo:

- ¿Existe relación entre la duración de una película y su valoración media?
- ¿Qué géneros predominan en las películas mejor valoradas de la historia?
- ¿Se observa alguna concentración temporal? ¿Hay décadas con mayor presencia en el Top 250?
- ¿Influye el número de votos en la estabilidad de la puntuación?
- ¿Aparecen ciertos directores o actores de forma recurrente en las películas mejor valoradas?
- ¿Se puede identificar un “perfil típico” de película altamente valorada?

Además, este dataset permite estudiar fenómenos interesantes desde el punto de vista del **análisis de datos sociales**, como el sesgo de popularidad, la influencia del paso del tiempo en la valoración cultural de una obra, o la relación entre producción cinematográfica y reconocimiento colectivo.

En comparación con análisis similares encontrados en estudios previos sobre datos cinematográficos (citados en el apartado 6), este dataset comparte la misma base conceptual: utilizar la información de IMDb como referencia para analizar patrones de éxito y reconocimiento en el cine. Sin embargo, a diferencia de muchos de esos estudios que utilizan datasets preconstruidos, en este caso se ha realizado todo el proceso de recolección de datos desde cero mediante técnicas de web scraping, lo que añade valor metodológico al proyecto.

8. Licencia

Para el dataset generado en este proyecto se ha seleccionado la licencia:

Creative Commons Attribution–NonCommercial–ShareAlike 4.0 (CC BY-NC-SA 4.0)

Descripción de la licencia

Esta licencia permite:

- **Compartir** el dataset (copiar y redistribuir el material en cualquier medio o formato).
- **Adaptar** el dataset (remezclar, transformar y crear a partir del material).

Bajo las siguientes condiciones:

- **Attribution (BY)**: se debe reconocer la fuente original de los datos (IMDb).
- **NonCommercial (NC)**: no se permite el uso del dataset con fines comerciales.
- **ShareAlike (SA)**: cualquier trabajo derivado debe distribuirse bajo la misma licencia.

Justificación de la elección

La elección de esta licencia está directamente relacionada con el origen de los datos, procedentes de IMDb:

- IMDb es una plataforma privada cuyo contenido está protegido por derechos de uso.
- Aunque los datos son públicos y accesibles, no están liberados como open data.
- Por tanto, no sería apropiado liberar el dataset bajo una licencia totalmente abierta como CC0 o CC BY.

La licencia **CC BY-NC-SA** garantiza que:

- Se reconoce la autoría original de la información.
- Se evita cualquier uso comercial indebido.
- Se mantiene el carácter académico y educativo del trabajo.
- Se obliga a que posibles reutilizaciones respeten las mismas condiciones.

Coherencia con el contexto del proyecto

Dado que:

- La recolección se ha realizado con fines docentes.
- El dataset contiene únicamente metadatos descriptivos.
- Se han respetado las normas de acceso del sitio web.

Esta licencia resulta la opción más coherente para proteger tanto el trabajo realizado como los derechos del propietario original de la información.

9. Código

El código implementado para la obtención del dataset se ha desarrollado en **Python** utilizando **Selenium** para la navegación autónoma y la interacción con el contenido dinámico del sitio web de IMDb.

El script se encuentra organizado de forma modular, separando claramente las funciones de:

- Inicialización del navegador y configuración del *User-Agent*.
- Descubrimiento automático de enlaces a las películas del Top 250.
- Extracción de los datos individuales de cada película.
- Almacenamiento estructurado del dataset en formato CSV.

Librerías utilizadas y versiones

Las versiones se han obtenido mediante el comando:

pip3 freeze > requirements.txt

Principales dependencias del proyecto:

Librería	Versión	Uso en el proyecto
selenium	4.21.0	Automatización del navegador y renderizado JS
webdriver-manager	4.0.1	Gestión automática del ChromeDriver

pandas	2.2.2	Estructuración y exportación del dataset
python-dotenv	1.0.1	Configuración del entorno (opcional)
urllib3	2.2.1	Dependencia de red
certifi	2024.2.	Certificados SSL
	2	

Navegador utilizado: **Google Chrome 138+**

WebDriver: **ChromeDriver** compatible gestionado automáticamente.

Aspectos más relevantes del proceso de recolección

El proceso de scraping presenta varias características que incrementan su complejidad y justifican el uso de Selenium frente a técnicas más simples como requests + BeautifulSoup:

Contenido dinámico generado por JavaScript

IMDb renderiza gran parte de la información mediante JavaScript. Por este motivo:

- Es necesario esperar explícitamente a que los elementos aparezcan en el DOM mediante WebDriverWait.
- No es posible acceder directamente al HTML estático inicial.

Descubrimiento autónomo de enlaces

El script **no parte de una lista fija de URLs**, sino que:

- Accede a la página del Top 250.
- Localiza dinámicamente los enlaces de cada película.
- Recorre de forma autónoma las 250 entradas.

Esto cumple el requisito de navegación automática indicado en la práctica.

Uso responsable del scraping

Para evitar sobrecargar el servidor:

- Se introducen pausas controladas con `time.sleep(2)` entre peticiones.

- Se utiliza un *User-Agent* realista de navegador.
- Se limita la extracción a 250 películas.

Extracción robusta de datos mediante selectores semánticos

En lugar de utilizar clases CSS volátiles, se emplean selectores basados en:

- data-testid
- Estructura semántica del DOM
- Elementos estables como <h1>, listas de metadatos y bloques técnicos

Esto hace que el scraper sea más resistente a pequeños cambios visuales del sitio.

Parsing del bloque JSON embebido

Parte de la información se obtiene del bloque:

<script type="application/ld+json">

Este bloque contiene metadatos estructurados en formato JSON-LD, lo que permite:

- Extraer título, año, duración, géneros y valoración de forma fiable.
- Evitar depender exclusivamente de elementos visuales.

Modularidad del código

El script está dividido en funciones independientes:

- init_driver()
- get_movie_links()
- scrape_movie()
- save_csv()
- main()

Esto facilita la comprensión, el mantenimiento y la reutilización del código.

10. Dataset.

Link Zenodo: **<https://doi.org/10.5281/zenodo.19476345>**

11. Vídeo

Debido a problemas con la cámara de ordenador, no se ha podido grabar el video.